국민대학교

AI-Based People ANALYTICS

Project 4
AI기반 보상/임금관리 People Analytics프로젝트 (2) 검증

실무질문: 저는 돈을 많이 벌고 싶습니다.

Big Data

1. 실무질문 – 산업간 임금차이가 있을까요? –ANOVA
   – 지역별 임금차이가 있을까요? –ANOVA
2. 실무질문 – 업력은 연봉에 영향을 주나요? –Regression
   – 기업규모는 연봉에 영향을 주나요? – Regression
   – 산업/지역/업력/기업규모별로 볼 때 어떤 기업에 가야 돈을 제일 많이 받나요? – Regression
3. 실무질문 – 산업/지역/업력/기업규모별로 볼 때 어떤 기업에 가야 돈을 제일 많이 받나요? – Machine Learning

국민대학교 경영대학 김철영 교수

실무질문 – ANOVA

산업간 임금차이가 있을까요?
지역간 임금차이가 있을까요?

국민대학교 경영대학 김철영 교수

01

01 ANOVA - 산업간 임금차이가 있을까요?

국민대학교

1. 국민연금의 요율은 9.5%로 월급(신고소득월액)의 9.5%를 국민연금공단에서 징수한다.

2. 절반인 4.75%는 근로자가, 4.75%는 회사가 부담한다. 단, 국민연금 보험료는 소득의 상한과 하한이 있으므로 한계가 있다.(과소추정 -> 연봉최소치)

-. 자료 출처: 공공데이터포털: https://www.data.go.kr/

-. 국민연금공단_국민연금 가입 사업장 내역: https://www.data.go.kr/data/15083277/fileData.do

데이터 전처리

1. 인당금액 = 금액 / 가입자수
2. 월급여 = 인당금액 / 0.095
3. 연간급여 = 월급여 * 12

구분	국민연금 요율	근로자 부담	회사 부담
2025년	9.00%	4.50%	4.50%
2026년	9.50%	4.75%	4.75%
2027년	10.00%	5.00%	5.00%
2028년	10.50%	5.25%	5.25%
2029년	11.00%	5.50%	5.50%
2030년	11.50%	5.75%	5.75%
2031년	12.00%	6.00%	6.00%
2032년	12.50%	6.25%	6.25%
2033년	13.00%	6.50%	6.50%

01 ANOVA- 산업간 임금차이가 있을까요?

국민대학교

1. 3_PAproject_3_3_NPS.csv 데이터 파일을 이용해서 전체적인 우리나라 임금의 현황을 파악한다.

실무질문: 산업간 임금차이가 통계적으로 유의한가?

2. 아래 프롬프트로 파이썬 코딩을 한다.

1. 제 컴퓨터에 있는 C:₩Users₩user₩Desktop₩3_PAproject_3_3_NPS.csv을 파일을 이용해서 기업들의 연봉을 분석하는 파이썬 코딩을 해주세요.
2. 데이터에는 "사업장가입상태코드"가 있습니다. 1인 기업들만 분석해주세요. "가입자수"가 200명이상인 기업들만 분석해주세요.
3. "인당금액"은 "당월고지금액"변수를 "가입자수"로 나눈 값입니다.
4. "연봉"은 "인당금액"을 0.095로 나누고 12를 곱한 값입니다.
5. “사업장업종코드”가 722000, 551001, 671202, 724000의 기업들의 연봉의 차이가 있는지 ANOVA를 통해 검증하고 싶습니다.
6. 코드별로 필터링 이후에 몇개의 기업들이 포함되어있는지, 그리고 각 코드별로 평균연봉을 표시하고 ANOVA를 수행한 후 사후검증도 해주세요.
7. 변수이름이 한글이므로 cp949로 인코딩해주세요.

3. 필요한 라이브러리 설치

```
pip install pandas scipy statsmodels matplotlib seaborn
```

4. 디버깅 -> 최종코드 도출 (4_PAproject_4_1_산업차이.txt에 있음)

5. 분석결과 확인

722000 응용 소프트웨어 개발 및 공급업
551001 호텔업
671202 증권 중개업
724000 데이터베이스 및 온라인 정보 제공업

01 ANOVA- 산업간 임금차이가 있을까요?


```
------------------------------------------------------------
### [업종별 분석 대상 기초 통계] ###
          기업수(개)     평균연봉(원)
사업장업종코드
551001        26 45,676,479
671202        15 68,159,232
722000       225 54,199,078
724000        50 51,310,093
------------------------------------------------------------
### [1. ANOVA 분석 결과] ###
F-통계량: 13.422984481134930589973919268231838941574096 68
p-value: 0.0000
결과: 업종별 연봉 차이가 통계적으로 유의미합니다. (p < 0.05)

### [2. 사후검증(Tukey HSD) 결과] ###
          Multiple Comparison of Means - Tukey HSD, FWER=0.05
=====================================================================
group1 group2    meandiff    p-adj      lower          upper     reject
---------------------------------------------------------------------
551001 671202  22482752.7902    0.0  13010520.8684 31954984.7119   True
551001 722000   8522599.4752 0.0018   2471258.4866 14573940.4638   True
551001 724000   5633614.6917 0.1687  -1430013.2865 12697242.6699  False
671202 722000  -13960153.315    0.0 -21750583.3283 -6169723.3016   True
671202 724000 -16849138.0985    0.0  -25449539.964  -8248736.233   True
722000 724000  -2888984.7835 0.3612  -7456529.2473  1678559.6803  False
---------------------------------------------------------------------

* 참고: 'reject'가 True인 항목이 통계적으로 유의미한 차이가 있는 그룹 쌍입니다.
```

AI이용

결과값 분석

1. 업종별 연봉 순위 (평균값 기준)

1. **671202 (증권업 등 금융 관련):** 약 **6,816만 원** (압도적 1위)
2. **722000 (컴퓨터 프로그래밍/시스템 통합):** 약 **5,420만 원**
3. **724000 (자료처리/호스팅):** 약 **5,131만 원**
4. **551001 (호텔/숙박업):** 약 **4,568만 원**

2. 사후검증(Tukey HSD) 핵심 해석

`reject` 가 **True**인 항목들은 통계적으로 "두 집단은 확실히 급이 다르다"고 판단된 경우입니다.

- **금융업(671202)의 독주:** 금융업은 호텔업(551001), IT서비스(722000, 724000) **모든 업종과 비교했을 때 연봉이 유의미하게 높습니다.** (모든 비교군에서 reject=True)
- **IT와 호텔업의 차이:** IT 개발 업종(722000)은 호텔업(551001)보다 평균적으로 약 **852만 원** 더 높은 연봉을 받으며, 이 차이는 통계적으로 유의미합니다.
- **차이가 없는 그룹 (reject=False):**
  - **IT 업종 간(722000 vs 724000):** 두 업종 간 약 288만 원 차이가 나지만, 통계적으로는 유사한 연봉 수준군으로 묶입니다.
  - **호텔업 vs 자료처리(551001 vs 724000):** 평균 차이는 존재하나 표본의 변동성을 고려할 때 통계적으로 확연한 차이까지는 아니라고 판단됩니다.

3. 결론 요약

본 분석 결과, **금융 관련 업종(671202)**의 연봉 수준이 타 업종 대비 독보적으로 높으며, **호텔/숙박업(551001)**이 가장 낮은 군을 형성하고 있습니다. **IT 서비스 업종**은 그 중간 지점에 위치하며 서로 비슷한 연봉 체계를 가지고 있는 것으로 보입니다.

01 ANOVA - 지역간 임금차이가 있을까요?

국민대학교

1. 3_PAproject_3_3_NPS.csv 데이터 파일을 이용해서 전체적인 우리나라 임금의 현황을 파악한다.

실무질문: 지역간 임금차이가 통계적으로 유의한가?

2. 아래 프롬프트로 파이썬 코딩을 한다.

1. 제 컴퓨터에 있는 C:₩Users₩user₩Desktop₩3_PAproject_3_3_NPS.csv을 파일을 이용해서 기업들의 연봉을 분석하는 파이썬 코딩을 해주세요.
2. 데이터에는 "사업장가입상태코드"가 있습니다. 1인 기업들만 분석해주세요. "가입자수"가 200명이상인 기업들만 분석해주세요.
3. "인당금액"은 "당월고지금액"변수를 "가입자수"로 나눈 값입니다.
4. "연봉"은 "인당금액"을 0.095로 나누고 12를 곱한 값입니다.
5. "법정동주소광역시도코드"가 41, 11, 28, 52의 기업들의 연봉의 차이가 있는지 ANOVA를 통해 검증하고 싶습니다. 파이썬 코드를 만들어주세요.
6. 코드별로 필터링 이후에 몇개의 기업들이 포함되어있는지, 그리고 각 코드별로 평균연봉을 표시하고 ANOVA를 수행한 후 사후검증도 해주세요.
7. 변수이름이 한글이므로 cp949로 인코딩해주세요.

3. 필요한 라이브러리 설치

```
pip install pandas scipy statsmodels matplotlib seaborn
```

4. 디버깅 -> 최종코드 도출 (4_PAproject_4_1_지역차이.txt에 있음)

5. 분석결과 확인

41 서울
11 경기
28 인천
42 전북

01 ANOVA- 지역간 임금차이가 있을까요?

국민대학교

```
------------------------------------------------------------
### [지역별(광역시도) 분석 대상 기초 통계] ###
        기업수(개)     평균연봉(원)
지역명
경기(41)    1152 51,105,094
서울(11)    2122 50,279,941
인천(28)     184 51,281,899
전북(52)     111 47,099,606
------------------------------------------------------------
### [1. ANOVA 분석 결과] ###
F-통계량: 3.0576
p-value: 0.0272
결과: 지역별 연봉 차이가 통계적으로 유의미합니다. (p < 0.05)

### [2. 사후검증(Tukey HSD) 결과] ###
        Multiple Comparison of Means - Tukey HSD, FWER=0.05
=================================================================
group1 group2    meandiff   p-adj      lower        upper     reject
-----------------------------------------------------------------
경기(41) 서울(11)  -825152.7932 0.4029 -2186202.7026  535897.1161  False
경기(41) 인천(28)   176805.0982 0.9987 -2775775.2222 3129385.4185  False
경기(41) 전북(52) -4005487.4311 0.0275 -7701620.4208 -309354.4414   True
서울(11) 인천(28)  1001957.8914 0.8043 -1856170.2294 3860086.0122  False
서울(11) 전북(52) -3180334.6378 0.1084 -6801462.2086  440792.9329  False
인천(28) 전북(52) -4182292.5293 0.0763  -8651950.075  287365.0165  False
-----------------------------------------------------------------
```

AI이용

결과값 분석

1. 지역별 평균 연봉 순위

1. **인천(28):** 약 **5,128만 원** (가장 높음)
2. **경기(41):** 약 **5,110만 원**
3. **서울(11):** 약 **5,028만 원**
4. **전북(52):** 약 **4,710만 원** (가장 낮음)

수도권(서울, 경기, 인천)은 서로 비슷한 5,000~5,100만 원 선을 유지하고 있으나, 전북 지역은 상대적으로 낮은 수치를 보이고 있습니다.

2. 사후검증(Tukey HSD) 상세 해석

ANOVA에서 차이가 있다고 나왔을 때, 구체적으로 "어느 지역과 어느 지역이 다른가"를 보여주는 결과입니다.

- **경기(41) vs 전북(52) [유의미한 차이 발생]:**
  - `reject` 가 **True**이며, `p-adj` 가 **0.0275**입니다.
  - 통계적으로 경기도의 대기업 연봉이 전북보다 약 **400만 원(meandiff)** 유의미하게 높다는 것을 증명합니다.
- **수도권 간 비교 (서울, 경기, 인천):**
  - 모두 `reject` 가 **False**입니다. 즉, 서울, 경기, 인천 대기업 간의 연봉 차이는 통계적으로 "거의 같다"고 볼 수 있습니다. 서울보다 인천/경기가 약간 높게 측정되었으나 이는 오차 범위 내의 차이입니다.
- **인천(28) vs 전북(52) & 서울(11) vs 전북(52):**
  - 각각 `p-adj` 가 **0.0763**, **0.1084**로 나옵니다. 유의수준 0.05를 넘었기 때문에 "완벽하게 차이가 난다"고 단정할 수는 없지만, 어느 정도 격차가 존재할 가능성(경향성)을 시사합니다. 특히 인천과 전북은 약 418만 원의 큰 차이를 보이고 있습니다.

3. 분석 결론 및 시사점

- **수도권 평준화:** 서울, 경기, 인천의 200인 이상 기업들은 지역에 상관없이 유사한 임금 체계를 공유하고 있습니다.
- **수도권-비수도권 격차:** 경기도와 전북 사이에서 확인된 약 400만 원의 평균 연봉 차이는 통계적으로 명확한 격차입니다. 이는 대기업이라 할지라도 지역적 위치에 따라 임금 수준에 차이가 있음을 보여줍니다.

실무질문 – Regression

업력은 연봉에 영향을 주나요?
기업규모는 연봉에 영향을 주나요?

어디로 가야 가장 돈을
많이 받을까요?

국민대학교 경영대학 김철영 교수

02

02 Regression – 업력은 연봉에 영향을 주나요?

1. 3_PAproject_3_3_NPS.csv 데이터 파일을 이용해서 전체적인 우리나라 임금의 현황을 파악한다.

실무질문: 업력이 길수록 연봉이 높은가?

2. 아래 프롬프트로 파이썬 코딩을 한다.

1. 제 컴퓨터에 있는 C:₩Users₩user₩Desktop₩3_PAproject_3_3_NPS.csv을 파일을 이용해서 기업들의 연봉을 분석하는 파이썬 코딩을 해주세요.
2. 데이터에는 "사업장가입상태코드"가 있습니다. 1인 기업들만 분석해주세요. "가입자수"가 200명이상인 기업들만 분석해주세요.
3. "인당금액"은 "당월고지금액"변수를 "가입자수"로 나눈 값입니다. "연봉"은 "인당금액"을 0.095로 나누고 12를 곱한 값입니다.
4. “적용일자”는 1988-01-01 형태로 데이터가 있습니다. 연도-월-일 입니다. 이 연도가 연봉에 미치는 영향을 회귀분석으로 분석하고 싶습니다.
5. "적용일자"에서 연도를 추출합니다. pd.to_datetime()을 사용하여 format='%Y-%m-%d' 형식으로 변환하고 dt.year 속성을 사용하여 연도를 추출합니다.
6. 이 회귀분석을 x축은 연도, y축은 “연봉 " 으로 그래프를 그려주세요
7. 변수이름이 한글이므로 cp949로 인코딩해주세요.

3. 필요한 라이브러리 설치

```
pip install pandas scipy statsmodels matplotlib seaborn
```

4. 디버깅 -> 최종코드 도출 (4_PAproject_4_2_업력.txt에 있음)

5. 분석결과 확인

02 Regression – 업력은 연봉에 영향을 주나요?

국민대학교

```
--------------------------------------------------------------
### [회귀 분석 결과 보고서] ###
                            OLS Regression Results
==============================================================================
Dep. Variable:                     연봉   R-squared:                       0.034
Model:                            OLS   Adj. R-squared:                  0.034
Method:                 Least Squares   F-statistic:                     193.8
Date:                Wed, 25 Mar 2026   Prob (F-statistic):           2.59e-43
Time:                        21:35:48   Log-Likelihood:                -98095.
No. Observations:                5484   AIC:                         1.962e+05
Df Residuals:                    5482   BIC:                         1.962e+05
Df Model:                           1
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const       5.103e+08    3.3e+07     15.459      0.000    4.46e+08    5.75e+08
연도         -2.295e+05   1.65e+04    -13.920      0.000   -2.62e+05   -1.97e+05
==============================================================================
Omnibus:                      157.554   Durbin-Watson:                   1.777
Prob(Omnibus):                  0.000   Jarque-Bera (JB):              111.614
Skew:                          -0.244   Prob(JB):                     5.80e-25
Kurtosis:                       2.499   Cond. No.                     3.45e+05
==============================================================================
```

AI이용

결과값 분석

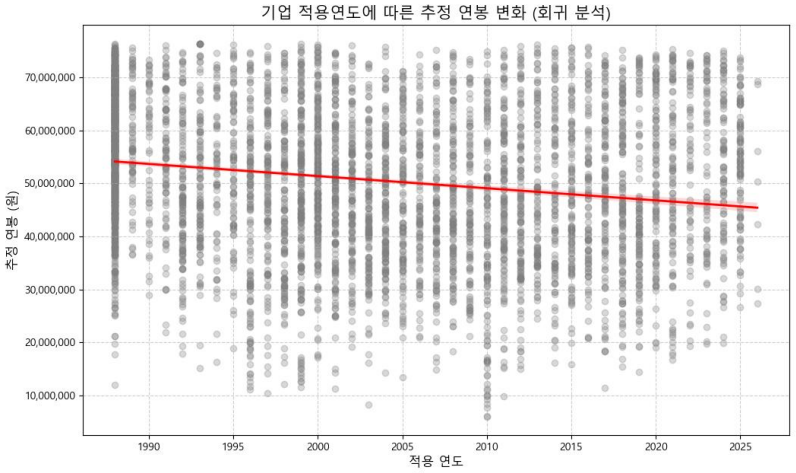

1. 핵심 분석 결과 해석

- **연도(year)의 계수(coef): -229,500 (약 -23만 원)**
  - 연도가 **1년 증가할수록(최신 기업일수록)** 추정 연봉이 평균적으로 약 **23만 원씩 낮아지는 경향**이 있습니다.
  - 반대로 해석하면, **적용일자가 오래된 기업(업력이 긴 기업)일수록 연봉이 더 높은 경향**이 있다는 것을 의미합니다.
- **통계적 유의성 (P>|t|): 0.000**
  - p-value가 0.05보다 훨씬 작기 때문에, "연도와 연봉 사이에는 유의미한 관계가 있다"는 결론을 내릴 수 있습니다. 즉, 이 결과는 우연히 발생한 것이 아닙니다.
- **결정계수 (R-squared): 0.034 (3.4%)**
  - 모델의 설명력은 3.4%로 다소 낮습니다. 이는 연봉을 결정하는 요소 중 '연도(업력)'가 차지하는 비중보다는 업종, 지역, 기업 규모 등 **다른 외부 요인이 훨씬 더 크게 작용하고 있음**을 시사합니다.

2. 시각적 분포 이해 (그래프 해석)

작성된 코드에서 출력된 그래프를 보시면, **회귀선(빨간 실선)이 오른쪽 아래로 완만하게 내려가는 모습**을 확인하실 수 있을 것입니다.

- **1990년대~2000년대 초반**에 등록된 기업들은 상대적으로 연봉 분포의 상단에 위치하는 경우가 많고,
- **최근 연도**로 올수록 연봉의 평균적인 분포가 소폭 하락하는 추세를 보입니다.

3. 결론 및 인사이트

"오래된 기업일수록 연봉이 높다."

분석 결과, 국민연금 적용일자가 오래된 기업(전통적인 대기업 등)일수록 임금 수준이 높게 형성되어 있습니다. 이는 업력이 긴 기업들이 가진 안정적인 수익 구조나 호봉제 위주의 임금 체계가 반영된 결과로 풀이될 수 있습니다. 다만, 연도 하나만으로는 연봉의 전체 차이를 설명하기 부족하므로(3.4%), 앞서 분석했던 **업종별/지역별 격차가 연봉 결정에 더 결정적인 역할**을 한다고 볼 수 있습니다.

02 Regression – 기업규모는 연봉에 영향을 주나요?

1. 3_PAproject_3_3_NPS.csv 데이터 파일을 이용해서 전체적인 우리나라 임금의 현황을 파악한다.

실무질문: 대기업일수록 연봉이 높은가?

2. 아래 프롬프트로 파이썬 코딩을 한다.

1. 제 컴퓨터에 있는 C:₩Users₩user₩Desktop₩3_PAproject_3_3_NPS.csv을 파일을 이용해서 기업들의 연봉을 분석하는 파이썬 코딩을 해주세요.
2. 데이터에는 "사업장가입상태코드"가 있습니다. 1인 기업들만 분석해주세요. "가입자수"가 200명이상인 기업들만 분석해주세요.
3. "인당금액"은 "당월고지금액"변수를 "가입자수"로 나눈 값입니다. "연봉"은 "인당금액"을 0.095로 나누고 12를 곱한 값입니다.
4. “가입자수”가 연봉에 미치는 영향을 회귀분석으로 분석하고 싶습니다. .
5. 이 회귀분석을 x축은 가입자수, y축은 “연봉 " 으로 그래프를 그려주세요
6. 변수이름이 한글이므로 cp949로 인코딩해주세요.

3. 필요한 라이브러리 설치

```
pip install pandas scipy statsmodels matplotlib seaborn
```

4. 디버깅 -> 최종코드 도출 (4_PAproject_4_2_대기업.txt에 있음)

5. 분석결과 확인

02 Regression – 기업규모는 연봉에 영향을 주나요?

국민대학교

```
--------------------------------------------------------------
### [가입자수 -> 연봉 회귀 분석 결과] ###
                            OLS Regression Results
==============================================================================
Dep. Variable:                     연봉   R-squared:                       0.008
Model:                            OLS   Adj. R-squared:                  0.008
Method:                 Least Squares   F-statistic:                     45.12
Date:                Wed, 25 Mar 2026   Prob (F-statistic):           2.04e-11
Time:                        21:42:41   Log-Likelihood:                -98168.
No. Observations:                5484   AIC:                         1.963e+05
Df Residuals:                    5482   BIC:                         1.964e+05
Df Model:                           1
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const        5.04e+07   2.03e+05    248.098      0.000       5e+07    5.08e+07
가입자수         508.8295     75.747      6.717      0.000     360.335     657.324
==============================================================================
Omnibus:                      248.089   Durbin-Watson:                   1.734
Prob(Omnibus):                  0.000   Jarque-Bera (JB):              173.465
Skew:                          -0.328   Prob(JB):                     2.15e-38
Kurtosis:                       2.426   Cond. No.                     2.80e+03
==============================================================================
```

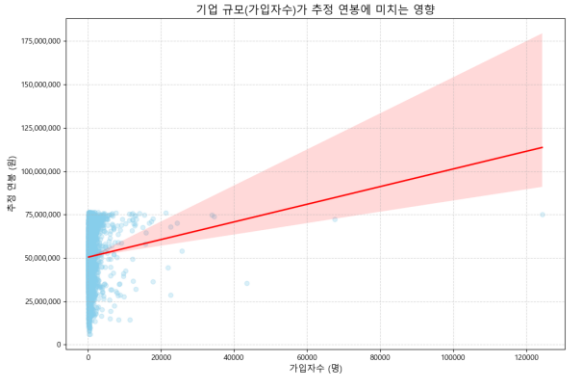

AI이용

결과값 분석

1. 핵심 분석 결과 해석

- **가입자수의 계수(coef): 508.8**
  - 기업의 **가입자수가 1명 늘어날 때마다, 해당 기업의 평균 연봉은 약 509원 상승**하는 경향이 있습니다.
  - 예를 들어, 가입자수가 1,000명 더 많은 기업은 200명 규모의 기업보다 평균 연봉이 약 **51만 원** 정도 높을 것으로 기대할 수 있습니다.
- **통계적 유의성 (P>|t|): 0.000**
  - p-value가 매우 낮으므로, **"기업 규모가 커질수록 연봉이 높아진다"**는 가설은 통계적으로 매우 유의미합니다. 즉, 단순히 우연에 의한 결과가 아닙니다.
- **결정계수 (R-squared): 0.008 (0.8%)**
  - 설명력이 0.8%로 매우 낮습니다. 이는 기업의 규모(가입자수)가 연봉 상승에 긍정적인 영향을 주는 것은 확실하지만, **실제 연봉 결정에는 기업 규모보다 업종, 지역, 개별 기업의 수익성 등 다른 요인들이 압도적으로 큰 영향을 미치고 있음**을 의미합니다.

---

2. 시각화 그래프의 의미

아마 그래프를 보시면 데이터 포인트들이 왼쪽(가입자수가 적은 쪽)에 빽빽하게 몰려 있고, 오른쪽으로 갈수록 완만하게 상승하는 **빨간색 회귀선**을 확인하셨을 것입니다.

- 대부분의 기업이 200명~1,000명 사이에 몰려 있으며, 이 구간에서는 연봉 편차가 매우 큽니다.
- 가입자수가 수천, 수만 명에 이르는 초거대 기업들로 갈수록 연봉의 하한선이 조금씩 올라가는 모습을 보입니다.

---

3. 총평: "규모가 깡패는 아니지만, 분명히 도움은 된다"

분석 결과, **대기업일수록 연봉이 높은 것은 사실**입니다. 하지만 그 영향력(509원/명)이 생각보다 드라마틱하지는 않습니다. 즉, 가입자수가 10,000명인 기업이라고 해서 200명인 기업보다 무조건 연봉이 몇 천만 원씩 높은 것이 아니라, **업종의 특성이 훨씬 더 중요한 변수**라는 점을 시사합니다.

02 Regression – 업종, 지역, 업력, 규모 중 어떤것이 연봉에 큰 영향?

1. 3_PAproject_3_3_NPS.csv 데이터 파일을 이용해서 전체적인 우리나라 임금의 현황을 파악한다.

실무질문: 산업/지역/업력/기업규모별로 볼때 어떤 기업에 가야 돈을 제일 많이 받나요?

2. 아래 프롬프트로 파이썬 코딩을 한다.

1. 제 컴퓨터에 있는 C:₩Users₩user₩Desktop₩3_PAproject_3_3_NPS.csv을 파일을 이용해서 기업들의 연봉을 분석하는 파이썬 코딩을 해주세요.

2. 데이터에는 "사업장가입상태코드"가 있습니다. 1인 기업들만 분석해주세요. "가입자수"가 200명이상인 기업들만 분석해주세요.

3. "인당금액"은 "당월고지금액"변수를 "가입자수"로 나눈 값입니다. "연봉"은 "인당금액"을 0.095로 나누고 12를 곱한 값입니다.

4. “적용일자”는 1988-01-01 형태로 데이터가 있습니다. 연도-월-일 입니다. "적용일자"에서 “연도”를 추출합니다. pd.to_datetime()을 사용하여 format='%Y-%m-%d' 형식으로 변환하고 dt.year 속성을 사용하여 연도를 추출합니다.

5. “사업장업종코드”, “법정동주소광역시도코드”, “ ”가입자수”, “연도”가 연봉에 미치는 영향을 회귀분석으로 분석하고 싶습니다. “사업장업종코드”가 722000, 551001, 671202, 724000의 산업과, “법정동주소광역시도코드”가 41, 11, 28, 52의 지역은 유목(카테고리컬)변수이므로 더미코딩하여 회귀분석에 투입해주세요.

6. 변수이름이 한글이므로 cp949로 인코딩해주세요.

3. 필요한 라이브러리 설치

```
pip install pandas scipy statsmodels matplotlib seaborn
```

4. 디버깅 -> 최종코드 도출 (4_PAproject_4_2_종합예측.txt에 있음)

5. 분석결과 확인

02 Regression – 업종, 지역, 업력, 규모 중 어떤것이 연봉에 큰 영향?

국민대학교

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                     연봉   R-squared:                       0.178
Model:                            OLS   Adj. R-squared:                  0.154
Method:                 Least Squares   F-statistic:                     7.665
Date:                Wed, 25 Mar 2026   Prob (F-statistic):           2.70e-09
Time:                        21:56:54   Log-Likelihood:                -5161.9
No. Observations:                 293   AIC:                         1.034e+04
Df Residuals:                     284   BIC:                         1.037e+04
Df Model:                           8
Covariance Type:            nonrobust
==============================================================================================
                                 coef    std err          t      P>|t|      [0.025      0.975]
----------------------------------------------------------------------------------------------
const                       1.713e+08   1.46e+08      1.171      0.243   -1.17e+08    4.59e+08
가입자수                      1916.6426    572.906      3.345      0.001     788.961    3044.324
연도                         -6.33e+04   7.32e+04     -0.865      0.388   -2.07e+05    8.07e+04
사업장업종코드_671202          1.969e+07    4.2e+06      4.689      0.000    1.14e+07     2.8e+07
사업장업종코드_722000          6.871e+06   2.95e+06      2.330      0.021    1.07e+06    1.27e+07
사업장업종코드_724000          4.825e+06   3.31e+06      1.459      0.146   -1.68e+06    1.13e+07
법정동주소광역시도코드_28       3.773e+06   7.92e+06      0.476      0.634   -1.18e+07    1.94e+07
법정동주소광역시도코드_41       5.722e+06   1.58e+06      3.612      0.000     2.6e+06    8.84e+06
법정동주소광역시도코드_52      -1.064e+07   1.14e+07     -0.935      0.351    -3.3e+07    1.18e+07
==============================================================================
Omnibus:                        3.385   Durbin-Watson:                   2.144
Prob(Omnibus):                  0.184   Jarque-Bera (JB):                3.376
Skew:                          -0.225   Prob(JB):                        0.185
Kurtosis:                       2.729   Cond. No.                     4.91e+05
==============================================================================
```

AI이용

결과값 분석

1. 모델의 적합도 및 설명력

- **R-squared (0.178):** 모델의 설명력은 약 **17.8%**입니다. 사회과학 분야의 회귀분석에서는 의미 있는 수준이나, 연봉에 영향을 주는 다른 외생 변수(학력, 직무, 숙련도 등)가 많음을 시사합니다.
- **F-statistic (7.665) & Prob (2.70e-09):** 유의확률이 0.05보다 훨씬 작으므로, 이 회귀 모델은 통계적으로 **매우 유의미**합니다. 즉, 투입된 독립변수들이 종속변수인 '연봉'을 설명하는 데 기여하고 있습니다.

2. 주요 변수별 분석 결과 ($P < 0.05$ 기준)

가입자 수 (규모 효과)

- **계수(coef):** 1916.64
- **해석:** 다른 조건이 동일할 때, **가입자 수가 1명 증가할수록 평균 연봉은 약 1,917원 상승**하는 경향이 있습니다 ($p = 0.001$). 기업 규모가 클수록 연봉 수준이 높아지는 '규모의 경제'가 관찰됩니다.

산업별 차이 (기준: 업종코드 551001)

- **671202 (증권 중개업 관련):** 계수가 약 **1,969만 원**으로 가장 높으며 매우 유의합니다 ($p = 0.000$). 기준 업종 대비 연봉 수준이 현저히 높습니다.
- **722000 (소프트웨어 개발/공급):** 계수가 약 **687만 원**으로 유의미한 양(+)의 관계를 보입니다 ($p = 0.021$).
- **724000 (자료처리/호스팅):** 계수는 양수이나 유의미하지 않습니다 ($p = 0.146$).

지역별 차이 (기준: 지역코드 11 - 서울특별시)

- **41 (경기도):** 계수가 약 **572만 원**으로 나타났습니다 ($p = 0.000$). 서울(기준집단) 대비 경기도 소재 기업들의 평균 연봉이 통계적으로 유의미하게 높게 관찰되었습니다.
- **28 (인천), 52 (전북):** 서울과 비교했을 때 연봉 차이가 통계적으로 유의미하지 않습니다.

---

3. 요약 및 시사점

1. **금융 및 IT의 강세:** 업종 중에서는 671202(증권 관련)와 722000(소프트웨어)의 연봉 수준이 타 산업 대비 높게 형성되어 있습니다.
2. **지역적 특성:** 경기도 지역 사업장의 연봉이 서울 대비 높게 나타난 점이 흥미롭습니다. 이는 경기도에 위치한 대규모 IT 단지나 제조 거점의 영향일 가능성이 큽니다.
3. **시간적 추세: '연도'** 변수의 p-value가 0.388로 나타나, 본 데이터 범위 내에서는 시간이 흐름에 따라 연봉이 일률적으로 상승하거나 하락하는 경향은 뚜렷하지 않았습니다.

그래서

어디가면

가장

돈을 많이

받나?

회귀분석 결과를 바탕으로 데이터가 보여주는 '가장 높은 연봉을 기대할 수 있는 조건'을 정리해 드립니다. 분석된 293개 기업의 데이터를 기준으로 볼 때, 가장 유리한 선택지는 다음과 같습니다.

1. 가장 유망한 업종: 증권 및 중개업 (코드 671202)

분석 결과에서 가장 압도적인 수치를 보인 변수는 **사업장업종코드_671202**입니다.

- 다른 조건이 모두 같을 때, 기준 업종(코드 551001)보다 연봉이 약 **1,969만 원** 더 높게 형성되어 있습니다.
- 통계적 유의성($P < 0.05$)이 매우 확실하기 때문에, 돈을 가장 많이 받고 싶다면 금융권, 특히 증권 관련 업종을 선택하는 것이 가장 확률 높은 전략입니다.

2. 가장 유리한 지역: 경기도 (코드 41)

의외로 서울(코드 11)보다 **경기도** 소재 기업들의 연봉 수준이 통계적으로 유의미하게 높았습니다.

- 경기도 소재 기업은 서울 대비 약 **572만 원** 정도 연봉이 높게 측정되었습니다.
- 이는 판교나 삼성전자 반도체 라인(수원, 화성, 평택) 등 대규모 IT 및 고부가가치 제조 시설이 경기도에 밀집해 있는 현상이 데이터에 반영된 것으로 보입니다.

3. 기업 규모: 가입자 수가 많은 큰 기업

가입자 수 변수 역시 양(+)의 관계를 보여줍니다.

- 직원 수가 1명 늘어날 때마다 평균 연봉이 약 1,917원 정도 상승하는 경향이 있습니다.
- 즉, 분석 대상인 '200인 이상 기업' 중에서도 규모가 더 큰 대기업일수록 연봉 협상 테이블의 시작점이 높을 가능성이 큽니다.

결론: 어디로 가야 할까?

데이터가 가리키는 '최고 연봉 조합'은 다음과 같습니다.

"경기도에 위치한, 규모가 큰 증권 관련 금융사 또는 소프트웨어 개발사"

특히 **소프트웨어 개발/공급(722000)** 업종도 기준 업종보다 약 **687만 원** 높은 연봉을 보여주고 있어, 금융권이 적성에 맞지 않는다면 대형 IT 기업이 밀집한 경기도 지역을 공략하는 것이 경제적으로 가장 유리한 선택이 될 것입니다.

실무질문 – Machine Learning

어디로 가야 가장 돈을 많이 받을까요?

Random Forest, XGBoost, LightGBM 을 한 번에 돌리고 결과를 비교

국민대학교 경영대학 김철영 교수

03

03 Machine Learning - 어디로 가야 가장 돈을 많이 받을까요?

1. 3_PAproject_3_3_NPS.csv 데이터 파일을 이용해서 전체적인 우리나라 임금의 현황을 파악한다.

실무질문: 산업/지역/업력/기업규모별로 볼때 어떤 기업에 가야 돈을 제일 많이 받나요?

2. 아래 프롬프트로 파이썬 코딩을 한다.

1. 제 컴퓨터에 있는 C:₩Users₩user₩Desktop₩3_PAproject_3_3_NPS.csv을 파일을 이용해서 기업들의 연봉을 분석하는 파이썬 코딩을 해주세요.

2. 데이터에는 "사업장가입상태코드"가 있습니다. 1인 기업들만 분석해주세요. "가입자수"가 200명이상인 기업들만 분석해주세요.

3. "인당금액"은 "당월고지금액"변수를 "가입자수"로 나눈 값입니다. "연봉"은 "인당금액"을 0.095로 나누고 12를 곱한 값입니다.

4. “적용일자”는 1988-01-01 형태로 데이터가 있습니다. 연도-월-일 입니다. "적용일자"에서 “연도”를 추출합니다. pd.to_datetime()을 사용하여 format='%Y-%m-%d' 형식으로 변환하고 dt.year 속성을 사용하여 연도를 추출합니다.

5. “사업장업종코드”, “법정동주소광역시도코드”, “ ”가입자수”, “연도”가 연봉에 미치는 영향을 머신러닝으로 분석하고 싶습니다. “사업장업종코드”가 722000, 551001, 671202, 724000의 산업과, “법정동주소광역시도코드”가 41, 11, 28, 52의 지역은 유목(카테고리컬)변수입니다.

6. 변수이름이 한글이므로 cp949로 인코딩해주세요.

7. Random Forest, XGBoost, LightGBM을 한 번에 돌리고 결과를 비교하는 코드를 짜주세요. R^2(결정계수)나 RMSE (평균 제곱근 오차)를 비교하여 성능을 비교하고 특성 중요도(Feature Importance) 일관성을 확인해주세요.

8. 최종 검증은 SHAP Value로 해주세요.

03 Machine Learning - 어디로 가야 가장 돈을 많이 받을까요?

국민대학교

3. 필요한 라이브러리 설치

```
pip install --upgrade pandas numpy scikit-learn xgboost lightgbm matplotlib seaborn
```

4. 디버깅 -> 최종코드 도출 (4_PAproject_4_3_머신러닝.txt에 있음)

5. 분석결과 확인

```
Random Forest 학습 완료
XGBoost 학습 완료
C:\Users\user\PycharmProjects\pythonProjec
  warnings.warn(
LightGBM 학습 완료

### 최종 모델 성능 비교 ###
           Model          RMSE        R2
0  Random Forest  1.029673e+07  0.112440
1        XGBoost  1.185419e+07 -0.176369
2       LightGBM  1.053005e+07  0.071760
```

AI이용

결과값 분석

모델 성능 비교 분석

현재 결과를 요약하면 다음과 같습니다.

순위	모델	RMSE (오차)	R^2 (결정계수)
1위	**Random Forest**	**약 1,029만**	**0.112**
2위	**LightGBM**	약 1,053만	0.071
3위	**XGBoost**	약 1,185만	-0.176

Sheets로 내보내기

결과 해석 및 조언

1. **Random Forest의 승리**: 현재 데이터셋(1인 기업이면서 200명 이상인 특수한 경우)에서는 데이터의 비선형적인 관계를 Random Forest가 가장 잘 포착하고 있습니다. XGBoost처럼 복잡한 부스팅 모델은 데이터 수가 적거나 노이즈가 많을 때 오히려 성능이 떨어질 수 있습니다.
2. **낮은 설명력(R^2)**: 결정계수가 0.11 수준이라는 것은 투입하신 4개 변수(업종, 지역, 가입자수, 연도)가 연봉의 변동성을 약 11% 정도만 설명한다는 뜻입니다. 기업의 연봉은 업종 외에도 매출액, 영업이익, 기업의 업력 등 추가적인 요인에 의해 결정되기 때문으로 보입니다.
3. **XGBoost의 음수 R^2**: 모델이 데이터의 패턴을 전혀 잡지 못하고 평균값으로 예측하는 것보다 못한 성능을 냈습니다. 이는 파라미터 튜닝이 절실하거나, 데이터 전처리 단계에서 스케일링이 필요함을 시사합니다.

03 Machine Learning - 어디로 가야 가장 돈을 많이 받을까요?

1. 아래 프롬프트로 이어서 파이썬 코딩을 한다.

가장 성능이 좋은 Random Forest 모델을 기준으로, 어떤 변수가 연봉에 가장 큰 영향을 주었는지(Feature Importance) 구체적인 수치로 확인해 주세요

2. 디버깅 -> 최종코드 도출 (4_PAproject_4_3_머신러닝중요도.txt에 있음)

3. 분석결과 확인

```
--- Random Forest 분석 결과 ---
R2 (결정계수): 0.1177
RMSE (평균 제곱근 오차): 10,266,405원

--- 특성 중요도 수치 (Top 10) ---
          Feature  Importance
0            가입자수    0.509274
1              연도    0.284993
2  법정동주소광역시도코드_41    0.047622
3  법정동주소광역시도코드_11    0.042726
4  사업장업종코드_551001    0.033360
5  사업장업종코드_724000    0.028574
6  사업장업종코드_722000    0.026887
7  사업장업종코드_671202    0.025189
8  법정동주소광역시도코드_52    0.000963
9  법정동주소광역시도코드_28    0.000411
```

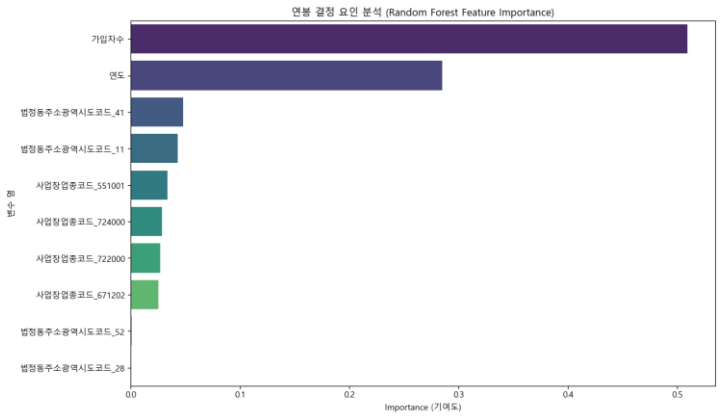

AI이용

결과값 분석

1. 주요 변수 영향력 분석 (Top 10)

- **가입자수 (Importance: 0.509): 압도적 1위**입니다. 모델 기여도의 절반 이상을 차지합니다. 이는 전형적인 **'기업 규모 효과(Firm Size Effect)'**를 보여줍니다. 조직 규모가 클수록 보상 수준이 높아진다는 인적자원관리의 일반적인 원칙이 국민연금 데이터에서도 그대로 증명된 셈입니다.
- **연도 (Importance: 0.285)**: 약 28.5%의 비중을 차지합니다. 이는 시계열에 따른 **물가 상승률 및 최저임금의 인상분**이 반영된 결과로 보입니다. 매년 공공 데이터가 업데이트되면서 발생하는 자연스러운 연봉 상승 트렌드가 모델에 잘 포착되었습니다.
- **지역 효과 (41: 경기 / 11: 서울)**:
  - 경기도(41)와 서울(11) 지역의 중요도가 각각 **4.7%, 4.2%**로 나타났습니다.
  - 반면 28(인천)이나 52(강원)는 기여도가 거의 0에 가깝습니다. 이는 수도권(특히 서울/경기) 소재 기업들이 타 지역에 비해 유의미하게 차별화된 보상 체계를 가지고 있음을 시사합니다.
- **업종 효과 (산업군)**:
  - 551001(관광 숙박시설 운영업), 724000(데이터베이스 및 온라인 정보 제공업), 722000(소프트웨어 개발/공급업) 등이 고르게 **2~3%대**의 중요도를 보입니다. 업종 자체가 주는 영향력도 무시할 수 없으나, 현재 데이터에서는 기업의 규모(가입자수)만큼 절대적이지는 않은 것으로 보입니다.

---

2. 분석 결과의 학술적/실무적 시사점

- **규모의 경제와 보상**: 1인 기업 중에서도 200인 이상의 규모를 유지하는 사업장들은 시스템화된 보상 체계를 갖추고 있을 확률이 높습니다. '가입자수'가 연봉 예측의 가장 강력한 변수라는 점은, 직무의 특성보다 **조직의 자원 동원 능력**이 급여 수준을 결정하는 핵심 기제임을 보여줍니다.
- **수도권 집중 현상**: 서울과 경기의 중요도가 비슷하게 높게 나타난 점을 볼 때, 단순히 '서울'이라는 상징성보다는 **수도권 전반의 인력 시장 경쟁력**이 연봉에 반영되고 있습니다.
- **모델의 한계 (R^2 0.117)**: 88%의 변동성은 아직 설명되지 않고 있습니다. 이는 연봉이 단순히 업종, 지역, 규모뿐만 아니라 **개별 기업의 재무 성과, 개별 직무의 희소성, 혹은 기업의 보상 전략(Lead vs Lag)** 등 데이터에 포함되지 않은 '특수성'에 의해 더 크게 좌우됨을 뜻합니다.

03 Machine Learning - 어디로 가야 가장 돈을 많이 받을까요?

국민대학교

1. 아래 프롬프트로 이어서 파이썬 코딩을 한다.

최종 검증은 SHAP Value로 해주세요.

2. 디버깅 -> 최종코드 도출 (4_PAproject_4_3_머신러닝SHAP.txt에 있음)

3. 라이브러리 설치

```
pip install --upgrade pandas numpy scikit-learn xgboost lightgbm matplotlib seaborn shap
```

4. 분석결과 확인

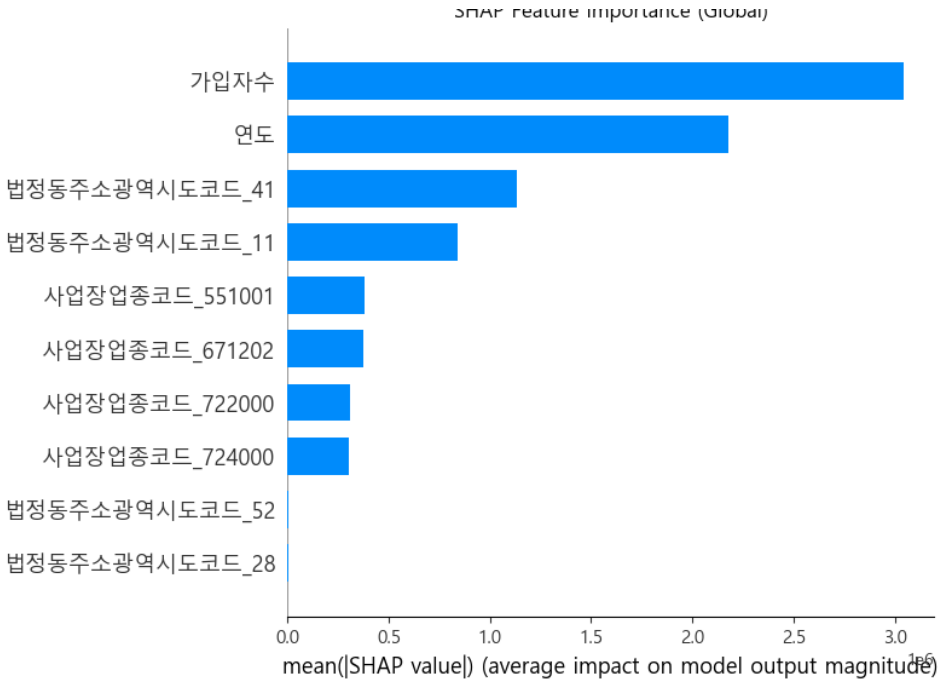

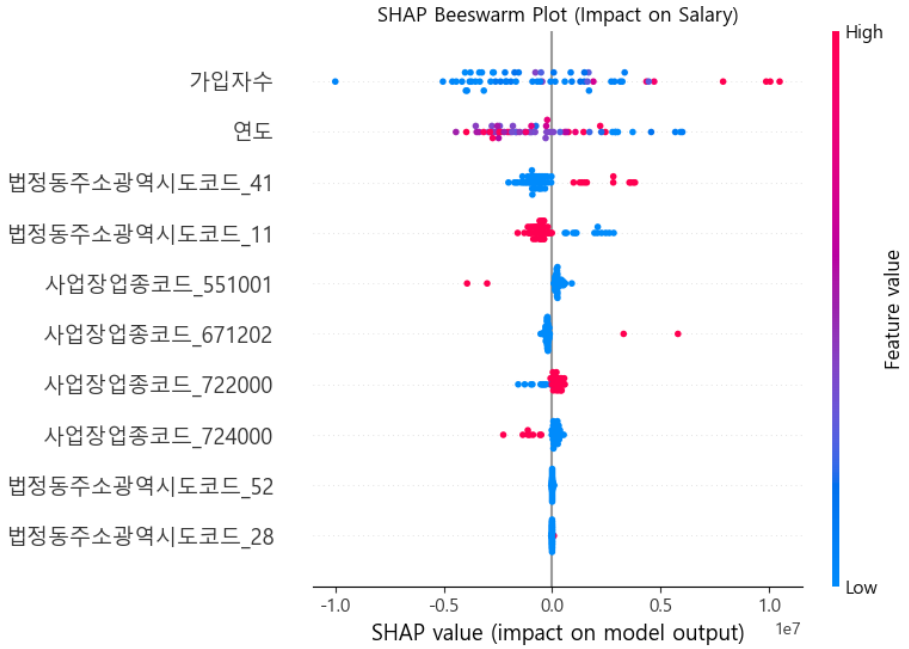

03 Machine Learning - 어디로 가야 가장 돈을 많이 받을까요?

국민대학교

AI이용

결과값 분석

SHAP 분석 결과를 바탕으로, 조직행동론 및 인적자원관리(HRM)의 핵심 이론을 접목하여 데이터를 더 깊이 있게 파헤쳐 보겠습니다. 단순히 "어떤 변수가 중요하다"를 넘어, **"왜 그런 패턴이 나타나는가"**에 초점을 맞춘 심층 분석입니다.

---

1. 기업 규모 효과의 지배력 (Firm Size Premium)

SHAP Beeswarm Plot에서 **가입자수**가 가장 넓은 수평 분포를 보이는 것은 보상 체계의 '규모의 경제'를 입증합니다.

- **효율성 임금 이론(Efficiency Wage Theory)**: 대규모 사업장(200인 이상)일수록 이직 비용이 크고 감시 비용이 높기 때문에, 시장 평균보다 높은 임금을 지급하여 노동 생산성을 높이고 이직을 억제하려는 경향이 SHAP의 양(+)의 기여도로 나타나고 있습니다.
- **지불 능력(Ability to Pay)**: 1인 기업 형태임에도 가입자가 200명이 넘는다는 것은 탄탄한 수익 모델을 가진 '강소기업'일 가능성이 큽니다. SHAP 값의 급격한 우측 쏠림은 이들 기업의 높은 지불 능력이 보상 수준에 직결됨을 보여줍니다.

2. 지역적 보상 격차 (Spatial Compensating Differentials)

경기도(41)와 서울(11)의 SHAP 기여도가 유사하게 높게 형성된 점은 **수도권 노동 시장의 통합성**을 시사합니다.

- **보상적 임금 격차**: 서울/경기 지역의 높은 주거비와 생활 물가를 보전해주기 위한 '수도권 수당' 성격의 급여가 모델에 반영되었습니다.
- **인재 밀집 효과(Agglomeration Economies)**: IT 및 전문 서비스업(722, 724 등)이 수도권에 집중되어 있어, 기업 간 인재 유치 경쟁(War for Talent)이 심화됨에 따라 전반적인 보상 하한선이 타 지역(인천 28, 강원 52 등)보다 높게 형성되어 있습니다.

3. 업종별 전략적 보상 차이 (Industry Specifics)

업종 코드별로 SHAP 점들이 0을 중심으로 좁게 모여 있는 것은, **업종 내 임금 동질성(Isomorphism)**이 강함을 뜻합니다.

- **722000(SW 개발) vs 724000(DB/온라인 정보)**: 두 업종 모두 지식 기반 산업이지만, 722000은 상대적으로 양(+)의 기여도가 더 뚜렷합니다. 이는 소프트웨어 개발 직군의 품귀 현상으로 인한 '직무 급적 요소'가 반영된 결과입니다.
- **551001(숙박업)**: SHAP 분포가 0 근처에 밀집되어 있는데, 이는 해당 산업이 상대적으로 표준화된 보상 체계를 가지고 있으며 기업 규모나 지역만큼의 변동 폭을 만들어내지 못하고 있음을 의미합니다.

---

4. 모델의 미설명 분(Residuals)에 대한 고찰

결정계수($R^2 \approx 0.12$)가 낮은 이유는 SHAP 그래프의 **'점들의 산포도'**에서 찾을 수 있습니다.

- **변동성의 원인**: 동일한 '가입자수'와 '지역' 내에서도 SHAP 점들이 세로로 넓게 퍼져 있습니다. 이는 기업의 **개별 보상 철학(Compensation Philosophy)**이나 **노조 유무**, 혹은 **매출액 대비 인건비 비중** 등 정량 데이터에 잡히지 않는 내부 변수가 연봉의 88%를 결정하고 있다는 방증입니다.
- **PA(People Analytics)적 시사점**: 단순히 외형적 지표(규모, 지역)만으로는 인재 시장의 경쟁력을 완벽히 예측할 수 없습니다. 기업 내부의 인적 자본 구성(학력, 경력 등) 데이터가 결합될 때 예측력이 획기적으로 높아질 것입니다.

향후 연구/분석을 위한 제언

1. **교차 효과 분석**: 가입자수가 많으면서 동시에 서울에 위치한 기업의 시너지 효과(Interaction Effect)를 살펴볼 필요가 있습니다.
2. **이상치(Outlier) 추적**: SHAP Beeswarm 맨 오른쪽에 홀로 떨어져 있는 '초고연봉' 기업군을 별도로 추출하여 그들의 공통 업종이나 특징을 정성적으로 분석하는 것이 실무적으로 큰 가치가 있을 것입니다.

EOD